

사업보고서 ESG 서술은 무엇을 측정하는가?

텍스트 기반 ESG 평가는 ESG를 재는가, 규모·공시 역량을 재는가 — 한국 사업보고서(DART) 381 기업-연도 분석

ESG 공시 의무화 확대

공시는 분명히 늘어난다. 문제는 그것이 '정보의 질'이 증가하는 것인지, '형식적 공시 역량 차이'가 증가하는 것인지다.



공시 확대'가 곧 정보 질 제고'는 아니다. ESG 대응이 약한 기업일수록 공시가 부실해 정보비대칭 해소가 시급 (이상호 2021, 자본시장연구원)

→ 늘어나는 텍스트는 ESG를 재는가, 규모·공시 역량을 재는가?

“기업이 쓴 ESG 언어 = 시장이 쓸 수 있는 실질 정보”인가?

공시 제도가 전제하는 이 등식이 실증적으로 얼마나 성립하는지를 묻는다

기업이 쓴 ESG 언어

= ?

시장에 쓸 수 있는 실질 정보

Q1 무엇을 재는가

텍스트는 실제 지속가능성을 반영하는가,
아니면 규모·공시 역량을 반영하는가?

Q2 구분되는가

E·S·G를 구분된 정보로 전달하는가,
아니면 뭉뚱그려진 ‘공시량’ 하나인가?

Q3 강건한가

측정(표현) 방식을 바꿔도 같은 결론이 나오는가?

이 등식이 깨지면 — 세 주체에게 각각 다른 질문이 된다: **정책당국** ‘무엇을 비교하나’ · **평가기관** ‘측정이 타당한가’ · **기업** ‘무엇이 진짜 경쟁력인가’

선행연구와 우리의 차별성

해외 질문을 한국 사업보고서로 비교 + 규모·분량을 제거해도 신호가 남는지 + 표현을 바꾸면 결과가 바뀌는지

해외

- Ignatov 2023 10-K ESG 톤은 주가에 반영되나 S-G만 유의·E는 시장이 무시
- Oehler & Neuss 2025 연차보고서 어휘가 ESG 등급의 상당 부분을 설명 (독일)
- Schimanski et al. 2024 차원(E·S·G)별 특화 언어모델이 필요
- Kimbrough et al. 2024 자발 공시는 불일치를 줄이나, 긍정 톤은 오히려 불일치 확대

국내

- 키워드·빈도·네트워크 분석 중심
뉴스·지속가능경영보고서 대상 (가독성·그린워싱 — 황용식 2025)
- KCGS 등급 활용 연구동향
김미옥 외 2025
- 최근 LLM로 서술 구체성·어조
아직 지속가능경영보고서 중심·기술적(descriptive) 단계

우리의 차별점 — 3겹

(a)

대상 이식

한국 사업보고서(DART)로 해외 질문을 옮긴다

(b)

통제 설계

규모·분량을 단계적으로 먼저 통제한다

(c)

측정 타당성

복수 측정치(4종)를 동일 스펙으로 나란히 비교


데이터와 분석 설계

127개사 × 3년 = 381 기업-연도, 같은 보고서를 4가지로 점수화

텍스트 점수 4트랙 (같은 보고서, 같은 전처리)

	단어 기반	의미 기반
비지도	seed TF-IDF fastText 확장	dense cosine
지도(등급 학습)	—	dense supervised

연구 설계: 한 문서 → 4트랙 점수화 → 등급 매칭 → 규모·분량 통제 → 회귀



핵심 직관

단어 세기는 “감사위원회를 설치했다”와 “설치하지 않았다”를 구별하지 못한다 (둘 다 단어가 있으므로) → 그래서 ‘의미도 함께 본다’

종속변수

KCGS ESG 등급 (E·S·G·통합), 서열 구조

통제 순서

규모(log 자산) → 분량 → 업종 → 연도 → (마지막) 텍스트


추정

순서형 로짓 · 기업 단위 군집 표준오차

텍스트보다 먼저, 규모가 등급을 설명한다

규모 단독 $\Delta R^2=0.433$ (단일 최대) vs 텍스트 고유 증분 $\leq 5\%p$ — 규모의 약 1/8

블록별 ESG 등급 설명력 증분 (ΔR^2 , 위계적 회귀 · OLS)



출처: 07d_a1_hierarchical.csv

43%

규모 한 변수가 단독 설명하는 등급 분산 (블록 $\Delta R^2=0.433$)

$\leq 5\%p$

통제 후 텍스트가 더하는 고유 신호 (규모의 $\sim 1/8$)

.63 $\rightarrow$.20

분량-등급 상관 $\rho \rightarrow$ 규모 통제 시 부분상관 (효과의 $\sim 2/3$ 가 규모 경유)

“어떤 표현을 써도 텍스트는 5%p를 못 넘고, 그 5%p마저 주로 한 차원에 몰린다.”

단어를 세면 G가 살고, 의미를 보면 S가 산다

완전통제 후 어느 ESG 차원도 4종 표현 중 과반에서 재현되지 않음 (E 0/4 · S 1/4 · G 1/4)

표현을 바꾸면 살아남는 차원이 바뀐다 — 완전통제 후 계수(β)

	E	S	G
① seed TF-IDF	+0.30 재현 안 됨	+0.00 재현 안 됨	+0.38 ** 생존
② fastText 확장	+0.24 재현 안 됨	+0.10 재현 안 됨	+0.30 재현 안 됨
③ dense cosine	+0.25 재현 안 됨	+0.09 재현 안 됨	-0.06 재현 안 됨
④ dense supervised	+0.16 재현 안 됨	+0.55 * 생존	+0.12 재현 안 됨

공통 축 하나
PC1이 설명하는 E·S·G 표현 분산


92%

E·S·G 텍스트 표현이 공통 축 하나로 수렴 → 차원 특정 신호라기보다 단일 ‘공시 충실도’에 가까움. 표현을 바꿔도 반복되는 건 오직 규모가 1차’.

G에선 ‘단어를 센’ seed TF-IDF만 생존 — ‘의미’는 모두 소멸

단어(seed) +0.38** vs 의미(cosine) -0.06 → 같은 G인데 서로 다른 방향을 가리켰다

G에선 ‘단어를 센’ seed TF-IDF만 생존 ($\beta=0.38^{**}$) — ‘의미’ 기반은 모두 소멸



단어와 의미가 역방향

‘핵심어(이사회·사외이사·감사위원회·주주)를 넣었는가’와
‘거버넌스를 의미 있게 서술했는가’는 서로 다른 정보.
(E·S에서는 두 접근이 같은 방향이었다)

형식적 이행 강화 위험


그 핵심어는 기업지배구조보고서·관련 법령 요구 항목과 대부분 중첩
G 신호는 실질 거버넌스 수준보다 ‘제도가 요구하는 형식을 채웠는가’
반영할 가능성.

→ 의무화 확대가 ‘실질 개선’이 아니라 ‘형식적 이행’을 강화할 위험.

S는 학습된 의미'에서만, E는 어느 방식으로도 안 잡힌다

S 생존 1/4 (dense supervised $\beta = +0.55^*$, G보다 큼) : "정답지로 학습해야 비로소 잡히는 의미"만 생존

E 생존 0/4 (통제 후 모두 소멸) : 환경 성과의 알맹이는 배출량, 감축률 등 정량지표가 중요할 가능성. 참고 : 미국 10-K에서도 E는 시장 반응이 약했다(Ignatov 2023)



차원마다 맞는 렌즈가 다르다 —G=단어 / S=학습된 의미 / E=정량지표. → 텍스트 ESG 점수의 대부분은 ESG가 아니라 규모·공시 충실도이고, 잣대마다 결과가 바뀐다. 그렇다면 누구에게, 무슨 의미인가?

정책당국 — 제도는 ‘ESG 수준’을 비교하나, ‘공시 역량’을 비교하나?

보완장치가 없으면, 의무화 확대가 ‘정보의 질’이 아니라 ‘공시 역량 격차’를 키울 위험

1 규모 중립성

- 등급 분산의 43%를 규모가 단독 설명.
- 분량·항목 충족으로 평가하면 대기업이 구조적으로 유리, 중소·중견은 불리.

KSSB ‘비교가능성’ 실질화 = 항목 확대가 아니라 규모 중립적 평가체계·규모별 보완장치

2 정보 다양성

- E·S·G 텍스트 표현이 공통 축 하나로 수렴 (PC1 92%).
- 텍스트가 세 영역을 ‘구분된 정보’로 담는다고 보기 어렵다.

차원별 정량지표·표준화 강화가 ‘공시량 확대’보다 중요

3 G 형식적 준수 위험

- 구조(키워드)만 등급과 연결, 운영(의미)은 역방향.
- 구조 중심(이사회 수·위원회 설치) 공시의 한계.

운영 중심(참석률·반대의견 비율·주주제안 수용) 공시로 전환 필요

비교가능성을 실현하는 길은 ‘항목 확대’가 아니라 ‘규모 중립 + 차원 분화 + 운영 정보’다.

평가기관 — ‘텍스트 단독 자동채점 = ESG 평가’는 성립하기 어렵다

측정 타당성(measurement validity) 검토: 결과가 방법에 민감하면 ‘점수만 공개’로는 검증 불가

세로축 · 충분성

텍스트 단독 설명력은 규모 통제 후 최대 5.3%p (규모 43%의 1/8). 최신 임베딩
당조차 0.7%p.

가로축 · 균질성

E-S-G는 정보 구조가 달라, 한 렌즈를 전 영역에 들이대면 차원 신호가 새어나
나간다.

차원마다 유효한 표현이 다르다

G

키워드(TF-IDF) 기반만 유의 — 제도화된 용어 중심

S

dense supervised(문맥·의미)만 유의 — 가치·문화·관계

E

어떤 방법도 안정 신호 실패 — 정량지표 중심

NLP 스코어링을 쓰려면 — 네 조건

- 1 규모·산업 보정 규모·업종이 만드는 구조적 편향을 먼저 제거
- 2 차원별 분화 E-S-G에 같은 모델을 일괄 적용하지 않는다
- 3 정량지표 결합 서술 + 배출량·감축률 등 검증 가능한 수치
- 4 산출 과정 투명성 최종 점수만이 아니라 방법·과정을 공개

기업 — 경쟁력은 ‘보고서의 두께’가 아니라 ‘검증 가능한 설명력’

규모·분량이 등급을 끌어올린다는 건, 역으로 ‘많이 쓰기’가 곧 실질 정보는 아니라는 뜻

1 분량 경쟁의 함정

- 규모·분량이 등급을 끌어올린다 = ‘많이 쓰기’가 곧 실질 정보는 아닐 수 있다.

공시량 경쟁이 아니라 정보의 구체성·전달력 중심
으로

2 정량·근거 결합

- 특히 E는 서술만으로 안정적 신호가 없었다.

배출량·감축률 등 검증 가능한 정량지표를 서술과
함께 제시 (cheap-talk 위험 회피)

3 커뮤니케이션 관점

- ESG 공시를 규제·평가 ‘대응’ 수단으로만 보지 않는다.

지속가능성 전략을 외부와 공유 — 핵심은 양이 아
니라 구체성·비교가능성·검증가능성


의무화 시대의 경쟁력 = ‘얼마나 많이 썼는가’가 아니라 ‘얼마나 신뢰할 수 있게 설명했다.’

신호는 '있다'이지 '세다'가 아니고, 준거(KCGS)부터 규모에 절여져 있다

통제 후 텍스트 약신호가 '텍스트의 한계'인지 '준거의 규모편향'인지 본 설계로는 분리 불가

- ① 준거의 규모편향 (가장 중요)
KCGS 등급 자체가 규모에 크게 좌우 (규모 단독 43%) → 멀티 평가기관 검증이 전제. 오
오늘 결론은 모두 KCGS 기준' 잠정.
- ② 약신호·표현 한정
통제 후 증분 $\leq 5\%$ 로 효과크기 작음 (0은 아님). G 잔존은 seed TF-IDF에 한정 (단,
규칙엔 강건).
- ③ 인과 아님·cheap-talk 가능
관찰연구·공시 강도 ≠ 실제 성과'.
- ④ null·표본 한계
E 0/4 = '없음' 이 아니라 '탐지 못함' (검정력). n=381(127사)·3년·단일 평가기관.

유의하지만 크지는 않다 — 부분 Spearman ρ (길이·규모 통제, 95% CI)



'유의 ≠ 중요', 그리고 '텍스트-KCGS 관계 ≠ 텍스트-실제 ESG 관계'. 약한 신호도, 준거의 한계도 부풀리지 않는 것이 이 연구의 신뢰성.

준거 편향을 푸는 것이 1순위 — 의무화 국면을 자연실험으로

의무화 前 베이스라인 + 규모별 시차 + 멀티 평가기관 = 측정 한계와 정책 효과를 함께 보는 발판

1

멀티 평가기관

KCGS 외 복수 등급으로 측정 강건성 + 준거 규모편향 분리.

평가사 간 ESG 등급 상관 0.38~0.71 (Berg, Koelbel & Rigobon 2022)

2

의무화 = 자연실험

2026 거버넌스 전면화 → 'G 신호' 유지 검증. 2028~ 규모별 시차 의무화.

30조→10조→전체 = staggered DiD의 천연 설계

3

공시-실질 괴리

통제 잔차로 cheap-talk 검증 + 수치 밀도 (specificity)로 분량·구체성 분리.

특히 E에서

4

업종별 이질성

제조(E 중심)·금융(G·S 중심) 등 표본 층분한 2~3개 업종 하위표본.

차원 중요도 차이 탐색

의무화 자연실험 타임라인

2026

거버넌스 보고서 전면화 — G 신호 유지/변화 검증

2028

연결자산 30조+ 의무 개시 (대조군: 비의무 기업)

2033

코스피 전체로 단계 확대 — staggered DiD 완성

“ESG 텍스트는 신호이지만, 순수한 ESG 신호는 아니다.”

01

무엇을 봤나

텍스트는 KCGS 등급과 관련 있으나,
대부분이 규모·분량·공시 역량을 경유
(규모 43% vs 텍스트 ≤5%p) · 표현에 민
민감 · 공통 축 수렴.

02

처음 질문의 답

공시는 늘어난다 — 그러나 보완장치
가 없으면 ‘정보의 질’보다 ‘형식적 공
적 공시 역량 차이’가 늘어날 위험.

03

누구에게

정책당국 = 규모 중립·운영 중심 / 평
가기관 = 보정·차원분화·정량결합·과
정투명 / 기업 = 두께가 아니라 검증
가능한 설명력.

04

이 연구의 정체성

‘텍스트-KCGS 관계’ ≠ ‘텍스트-실제
실제 ESG 관계’ — 무엇을 재고 무엇을
엇을 못 재는지를 드러내는 측정 타당
성 연구.

감사합니다.